

Code Metrics Dataset (SoftwareProjectStructure) - Kapsamlı Analiz Raporu

Ders: Yazılım Test Sürecinin Optimizasyonu İçin Yapay Zeka Yöntemleri

1. Veri Seti Tanımı (Dataset Description)


Bu veri seti, yazılım projelerinin kaynak kod metriklerini içermektedir. Java projelerinden elde edilen CK (Chidamber-Kemerer) ve diğer nesne yönelimli tasarım metrikleri, sınıf düzeyinde ölçümlenmiştir. Veri seti, yazılım refactoring ihtiyacının tahmin edilmesi amacıyla oluşturulmuş olup, "trivial" ve "non-trivial" refactoring olmak üzere iki alt dosyadan meydana gelmektedir.

- Kaynak:** Kaggle - Code Metrics Dataset SoftwareProjectStructure
- Dosya Formatı:** CSV
- Toplam Dosya Sayısı:** 2
- Toplam Veri Boyutu:** 158.75 MB
- Toplam Gözlem Sayısı:** 741,894
- Özellik Sayısı:** 53

2. Yapısal Analiz (Structural Analysis)

2.1 Dosya Yapısı

Dosya	Boyut (MB)	Gözlem Sayısı	Özellik Sayısı
OnlyNonTrivial_dt.csv	109.96	509,426	53
OnlyTrivial_dt.csv	48.79	232,468	53
Toplam	158.75	741,894	53



2.2 Veri Boyutu ve Tipleri

Metrik	Değer
Toplam gözlem (satır) sayısı	741,894
Özellik (sütun) sayısı	53
int64 tipi sütun sayısı	47
float64 tipi sütun sayısı	3
object tipi sütun sayısı	3

2.3 Sütun Detayları

Sütun Adı	Veri Tipi	Açıklama
refactoring	int64	Hedef değişken (0/1)
file	object	Kaynak dosya yolu
class	object	Sınıf adı
type	object	Sınıf tipi (class, interface, enum, innerclass, anonymous)
cbo	int64	Coupling Between Objects

Sütun Adı	Veri Tipi	Açıklama
cboModified	int64	Modifiye CBO
fanin	int64	Fan-in (gelen bağımlılıklar)
fanout	int64	Fan-out (giden bağımlılıklar)
wmc	int64	Weighted Methods per Class
dit	int64	Depth of Inheritance Tree
noc	int64	Number of Children
rfc	int64	Response for a Class
lcom	int64	Lack of Cohesion of Methods
lcom*	float64	Normalize edilmiş LCOM
tcc	float64	Tight Class Cohesion
lcc	float64	Loose Class Cohesion
totalMethodsQty	int64	Toplam metot sayısı
staticMethodsQty	int64	Statik metot sayısı
publicMethodsQty	int64	Public metot sayısı
privateMethodsQty	int64	Private metot sayısı
protectedMethodsQty	int64	Protected metot sayısı
defaultMethodsQty	int64	Default metot sayısı
visibleMethodsQty	int64	Erişilebilir metot sayısı
abstractMethodsQty	int64	Abstract metot sayısı
finalMethodsQty	int64	Final metot sayısı
synchronizedMethodsQty	int64	Synchronized metot sayısı
totalFieldsQty	int64	Toplam alan (field) sayısı
staticFieldsQty	int64	Statik alan sayısı
publicFieldsQty	int64	Public alan sayısı
privateFieldsQty	int64	Private alan sayısı
protectedFieldsQty	int64	Protected alan sayısı
defaultFieldsQty	int64	Default alan sayısı
finalFieldsQty	int64	Final alan sayısı
synchronizedFieldsQty	int64	Synchronized alan sayısı
nosi	int64	Number of Static Invocations

Sütun Adı	Veri Tipi	Açıklama
loc	int64	Lines of Code
returnQty	int64	Return ifade sayısı
loopQty	int64	Döngü sayısı
comparisonsQty	int64	Karşılaştırma sayısı
tryCatchQty	int64	Try-catch blok sayısı
parenthesizedExpsQty	int64	Parantez ifade sayısı
stringLiteralsQty	int64	String literal sayısı
numbersQty	int64	Sayı literal sayısı
assignmentsQty	int64	Atama sayısı
mathOperationsQty	int64	Matematik işlem sayısı
variablesQty	int64	Değişken sayısı
maxNestedBlocksQty	int64	Maksimum iç içe blok derinliği
anonymousClassesQty	int64	Anonim sınıf sayısı
innerClassesQty	int64	İç sınıf sayısı
lambdasQty	int64	Lambda ifade sayısı
uniqueWordsQty	int64	Benzersiz kelime sayısı
modifiers	int64	Modifier sayısı
logStatementsQty	int64	Log ifade sayısı

3. Betimleyici İstatistikler (Descriptive Statistics)

3.1 Sayısal Değişkenlerin Özet İstatistikleri

Değişken	Ortalama	Medyan	Std Sapma	Min	Max	Çarpıklık	Basıklık
cbo	5.1561	3.0	5.8931	0	192	4.2396	62.6666
cboModified	6.8967	5.0	7.4942	0	471	6.9031	270.2567
fanin	1.7406	1.0	3.8387	0	469	33.4526	3660.4778
fanout	5.1562	3.0	5.8932	0	192	4.2395	62.665
wmc	7.6432	3.0	14.9835	0	666	9.6888	219.9243
dit	1.4315	1.0	0.8218	1	75	5.6543	221.9581
noc	0.1058	0.0	0.8426	0	25	16.2012	354.7236
rfc	8.103	3.0	14.227	0	237	4.5396	33.3049

Değişken	Ortalama	Medyan	Std Sapma	Min	Max	Çarpıklık	Basıklık
lcom	36.0081	0.0	1504.0433	0	221445	106.0877	12102.9184
loc	36.8468	15.0	87.9248	1	6667	29.9193	1660.9943
totalMethodsQty	4.599	2.0	8.8134	0	666	25.7606	1455.8686
totalFieldsQty	2.2682	1.0	4.776	0	149	8.9666	159.2861
nosi	0.9941	0.0	4.6066	0	604	60.8274	7182.3364
returnQty	2.4587	0.0	7.8062	0	666	36.5133	2401.1126
loopQty	0.4299	0.0	1.8194	0	77	10.2283	179.7172
comparisonsQty	1.0232	0.0	3.6482	0	153	10.4018	224.0721
variablesQty	5.4887	2.0	11.3463	0	369	6.6908	83.8105
maxNestedBlocksQty	0.7122	0.0	1.1038	0	14	2.3434	9.3081
uniqueWordsQty	31.1643	19.0	44.8212	0	2866	18.5622	994.9848

3.2 Çeyreklik Değerleri

Değişken	Q1	Q3	IQR
cbo	1.0	7.0	6.0
cboModified	2.0	9.0	7.0
fanin	0.0	2.0	2.0
fanout	1.0	7.0	6.0
wmc	1.0	8.0	7.0
dit	1.0	2.0	1.0
noc	0.0	0.0	0.0
rfc	0.0	10.0	10.0
lcom	0.0	4.0	4.0
loc	7.0	39.0	32.0
totalMethodsQty	1.0	5.0	4.0
totalFieldsQty	0.0	3.0	3.0
nosi	0.0	1.0	1.0
returnQty	0.0	2.0	2.0
loopQty	0.0	0.0	0.0
comparisonsQty	0.0	0.0	0.0

Değişken	Q1	Q3	IQR
variablesQty	0.0	6.0	6.0
maxNestedBlocksQty	0.0	1.0	1.0
uniqueWordsQty	9.0	39.0	30.0


Çarpıklık Yorumu: Tüm değişkenler güçlü pozitif çarpıklık göstermektedir. Özellikle **lcom** (106.09), **nosi** (60.83) ve **returnQty** (36.51) aşırı sağa çarpık dağılımlara sahiptir. Bu, kod metriklerinin büyük çoğunluğunun düşük değerlerde yoğunlaştığını, az sayıda sınıfın çok yüksek karmaşıklık değerlerine sahip olduğunu göstermektedir.

Basıklık Yorumu: Tüm değişkenlerde yüksek pozitif basıklık (leptokurtik) gözlemlenmektedir. **lcom** (12102.92) ve **nosi** (7182.34) gibi değişkenler aşırı sivri dağılımlara sahiptir. Bu durum, uç değerlerin varlığına ve ağır kuyruklu dağılımlara işaret etmektedir.

4. Dağılım Analizi (Distribution Analysis)



Her sayısal değişken için histogram ve boxplot grafikleri oluşturulmuştur.

4.1 cbo (Coupling Between Objects)





- **IQR Alt Sınır:** -8.0
- **IQR Üst Sınır:** 16.0
- **Outlier Sayısı:** 33,701 (%4.54)

4.2 cboModified





- **IQR Alt Sınır:** -8.5
- **IQR Üst Sınır:** 19.5
- **Outlier Sayısı:** 42,581 (%5.74)

4.3 fanin




- **IQR Alt Sınır:** -3.0
- **IQR Üst Sınır:** 5.0
- **Outlier Sayısı:** 57,294 (%7.72)

4.4 fanout




- **IQR Alt Sınır:** -8.0
- **IQR Üst Sınır:** 16.0
- **Outlier Sayısı:** 33,701 (%4.54)

4.5 wmc (Weighted Methods per Class)





- **IQR Alt Sınır:** -9.5
- **IQR Üst Sınır:** 18.5
- **Outlier Sayısı:** 69,918 (%9.42)

4.6 dit (Depth of Inheritance Tree)





- **IQR Alt Sınır:** -0.5
- **IQR Üst Sınır:** 3.5
- **Outlier Sayısı:** 20,401 (%2.75)

4.7 noc (Number of Children)





- **IQR Alt Sınır:** 0.0
- **IQR Üst Sınır:** 0.0
- **Outlier Sayısı:** 28,225 (%3.8)

4.8 rfc (Response for a Class)





- **IQR Alt Sınır:** -15.0
- **IQR Üst Sınır:** 25.0
- **Outlier Sayısı:** 56,150 (%7.57)

4.9 lcom (Lack of Cohesion of Methods)





- **IQR Alt Sınır:** -6.0
- **IQR Üst Sınır:** 10.0
- **Outlier Sayısı:** 119,210 (%16.07)

4.10 loc (Lines of Code)





- **IQR Alt Sınır:** -41.0
- **IQR Üst Sınır:** 87.0
- **Outlier Sayısı:** 69,575 (%9.38)

4.11 totalMethodsQty





- **IQR Alt Sınır:** -5.0
- **IQR Üst Sınır:** 11.0
- **Outlier Sayısı:** 63,883 (%8.61)

4.12 variablesQty





- **IQR Alt Sınır:** -9.0
- **IQR Üst Sınır:** 15.0
- **Outlier Sayısı:** 66,315 (%8.94)

4.13 comparisonsQty




- **IQR Alt Sınır:** 0.0
- **IQR Üst Sınır:** 0.0
- **Outlier Sayısı:** 173,364 (%23.37)

4.14 uniqueWordsQty



- **IQR Alt Sınır:** -36.0
- **IQR Üst Sınır:** 84.0
- **Outlier Sayısı:** 51,075 (%6.88)


Genel Boxplot Karşılaştırması



5. Hedef Değişken Analizi (Target Variable Analysis)

Bu veri setinde hedef değişken **refactoring** olup ikili sınıflandırma (binary classification) problemi için kullanılmaktadır. Değer 1 sınıfta refactoring uygulandığını, 0 ise uygulanmadığını göstermektedir.


5.1 Birleşik Veri Seti - Refactoring Dağılımı



Sınıf	Frekans	Oran
Refactoring (1)	377,879	%50.9
Non-Refactoring (0)	364,015	%49.1

- **Çoğunluk sınıfı:** Refactoring (1) (%50.93)
- **Azınlık sınıfı:** Non-Refactoring (0) (%49.07)
- **Dengesizlik oranı:** 1.0381
- **Dengesizlik (Imbalance) var mı?** Hayır
- **SMOTE gerekli mi?** Hayır


5.2 Alt Veri Setleri Bazında Dağılım



Veri Seti	Refactoring (1)	Non-Refactoring (0)	Oran
NonTrivial	258,010 (%50.65)	251,416 (%49.35)	1.0262
Trivial	119,869 (%51.55)	112,599 (%48.45)	1.0646

Her iki alt veri setinde de sınıf dengesi korunmaktadır.

5.3 Sınıf Tipi (type) Dağılımı




Tip	Frekans	Oran
class	440,303	%59.3
anonymous	120,676	%16.3

Tip	Frekans	Oran
innerclass	98,945	%13.3
interface	64,924	%8.8
enum	17,046	%2.3

6. Korelasyon ve Bağımlılık Analizi (Correlation & Dependency Analysis)

6.1 Pearson Korelasyon Matrisi



6.2 En Yüksek Korelasyonlar

Değişken 1	Değişken 2	Korelasyon
cbo	fanout	1.0000
totalMethodsQty	returnQty	0.8764
wmc	totalMethodsQty	0.8299

Değişken 1	Değişken 2	Korelasyon
wmc	loc	0.8291
loc	totalMethodsQty	0.8268
loc	returnQty	0.7860
rfc	variablesQty	0.7859
wmc	returnQty	0.7677
lcom	returnQty	0.7328
wmc	comparisonsQty	0.7270
cbo	rfc	0.7144
fanout	rfc	0.7144
totalFieldsQty	variablesQty	0.7049
wmc	rfc	0.6874
wmc	variablesQty	0.6699



Yorum: **cbo** ve **fanout** arasında mükemmel korelasyon (1.0) bulunmaktadır; bu iki metrik aynı bilgiyi taşımaktadır. Ayrıca **wmc**, **loc**, **totalMethodsQty** ve **returnQty** arasında güçlü (>0.75) korelasyonlar mevcuttur. Bu durum, sınıf büyüklüğünü yansıtan metriklerin birbirleriyle yüksek bağımlılık gösterdiğine işaret etmektedir.

6.3 Chi-Square Bağımsızlık Testleri (Kategorik Değişkenler)

Değişken 1	Değişken 2	χ^2	p-değeri	Cramér's V	Anlamlı?
type	refactoring	32.2842	0.000002	0.0066	Evet
dataset	refactoring	53.6095	0.000000	0.0085	Evet
type	dataset	9936.5048	0.000000	0.1157	Evet

Yorum: Tüm kategorik değişken çiftleri için istatistiksel olarak anlamlı ilişki tespit edilmiştir ($p < 0.05$). Ancak Cramér's V değerleri düşük olup, bu ilişkilerin pratikte zayıf olduğunu göstermektedir. **type** ile **dataset** arasındaki ilişki görece daha güçlüdür ($V = 0.1157$).

6.4 Çapraz Tablolar




6.5 ANOVA Testi (Sayısal ~ Refactoring)

Değişken	F-İstatistik	p-değeri	Anlamlı?
cbo	22.4663	0.000002	Evet
cboModified	24.35	0.000001	Evet
fanin	5.6694	0.017263	Evet

Değişken	F-İstatistik	p-değeri	Anlamlı?
fanout	22.3179	0.000002	Evet
wmc	14.4756	0.000142	Evet
dit	4.5803	0.032342	Evet
noc	3.4887	0.061788	Hayır
rfc	7.3758	0.006611	Evet
lcom	0.0026	0.959652	Hayır
loc	4.8474	0.027689	Evet
totalMethodsQty	8.5495	0.003456	Evet
totalFieldsQty	2.6236	0.105287	Hayır
nosi	8.846	0.002937	Evet
returnQty	4.6576	0.030917	Evet
loopQty	0.8205	0.365045	Hayır
comparisonsQty	14.5406	0.000137	Evet
variablesQty	0.3219	0.570462	Hayır
maxNestedBlocksQty	19.283	0.000011	Evet
uniqueWordsQty	0.267	0.605325	Hayır

En Anlamlı Değişkenler ~ Refactoring (ANOVA)




Yorum: **cboModified** (F=24.35), **cbo** (F=22.47), **maxNestedBlocksQty** (F=19.28), **wmc** (F=14.48) ve **comparisonsQty** (F=14.54) değişkenleri refactoring hedef değişkeni ile istatistiksel olarak anlamlı farklılıklar

göstermektedir. Bu metrikler, refactoring ihtiyacının tahmin edilmesinde potansiyel olarak önemli özelliklerdir.

7. Çoklu Doğrusal Bağıntı Analizi (Multicollinearity)

VIF (Variance Inflation Factor) değerleri hesaplanmıştır. VIF > 10 ciddi, VIF > 5 orta düzey multicollinearity anlamına gelir.




Değişken	VIF	Ciddi MC? (>10)	Orta MC? (>5)
cbo	188,907.84	Evet	Evet
fanin	1.22	Hayır	Hayır
fanout	188,904.08	Evet	Evet
wmc	19.24	Evet	Evet
dit	1.09	Hayır	Hayır
noc	1.08	Hayır	Hayır
rfc	4.65	Hayır	Hayır
lcom	4.31	Hayır	Hayır
loc	9.83	Hayır	Evet
totalMethodsQty	9.51	Hayır	Evet
totalFieldsQty	2.41	Hayır	Hayır
nosi	1.34	Hayır	Hayır
returnQty	5.76	Hayır	Evet
loopQty	2.54	Hayır	Hayır
comparisonsQty	3.44	Hayır	Hayır

Değişken	VIF	Ciddi MC? (>10)	Orta MC? (>5)
variablesQty	6.33	Hayır	Evet
maxNestedBlocksQty	1.93	Hayır	Hayır
uniqueWordsQty	2.26	Hayır	Hayır

Sonuç: **cbo** ve **fanout** arasında aşırı yüksek VIF değerleri (188,907) tespit edilmiştir. Bu, iki değişkenin neredeyse aynı bilgiyi taşıdığını (korelasyon = 1.0) doğrulamaktadır. **wmc** (VIF=19.24) değişkeninde de ciddi multicollinearity mevcuttur. Model oluşturmadan önce **fanout** veya **cbo**'dan birinin çıkarılması ve **wmc** ile ilişkili değişkenlerin gözden geçirilmesi önerilmektedir.

8. Boyut Analizi (Dimensionality Analysis)

8.1 PCA (Principal Component Analysis)




Bileşen	Açıklanan Varyans (%)	Kümülatif (%)
PC1	43.59	43.59
PC2	11.15	54.74
PC3	7.12	61.86
PC4	6.88	68.74
PC5	5.51	74.25
PC6	4.58	78.83
PC7	4.39	83.22
PC8	3.94	87.16
PC9	2.98	90.14

Bileşen	Açıklanan Varyans (%)	Kümülatif (%)
PC10	2.54	92.68
PC11	2.41	95.09

- %85 varyans için gereken bileşen sayısı: 8
- %90 varyans için gereken bileşen sayısı: 9
- %95 varyans için gereken bileşen sayısı: 11

Yorum: İlk bileşen (PC1) tek başına varyansın %43.59'unu açıklamaktadır. Bu, veri setindeki değişkenlerin önemli bir kısmının ortak bir faktör (sınıf büyüklüğü/karmaşıklığı) ile ilişkili olduğunu göstermektedir. 18 değişkenden %95 varyansı açıklamak için 11 bileşen gerekmektedir; bu da moderat düzeyde bir boyut indirgeme fırsatı sunmaktadır.

8.2 PCA 2D Scatter Plot



9. Veri Kalitesi Değerlendirmesi (Data Quality Assessment)

9.1 Eksik Veri (Missing Values)

Sütun	Eksik Değer	Oran (%)
lcom*	19,683	%2.65
tcc	239,016	%32.22
lcc	239,016	%32.22
Diğer tüm sütunlar	0	%0.0

Yorum: **tcc** (Tight Class Cohesion) ve **lcc** (Loose Class Cohesion) sütunlarında yaklaşık %32 oranında eksik değer bulunmaktadır. Bu sütunlar, metot çiftleri arasındaki bağlantılılık ölçütleridir ve yalnızca yeterli sayıda metot bulunan sınıflarda hesaplanabilir. **lcom*** sütununda ise %2.65 oranında eksik değer mevcuttur.

9.2 Tekrarlayan Kayıtlar (Duplicates)

- **NonTrivial tekrarlayan satır:** 0
- **Trivial tekrarlayan satır:** 0
- **Birleşik tekrarlayan satır:** 0
- **Tekrarlama oranı:** %0.0

9.3 Gürültülü Veri ve Anormal Değerler

IQR yöntemiyle tespit edilen outlier'lar:

Değişken	Alt Sınır	Üst Sınır	Outlier Sayısı	Oran (%)
cbo	-8.0	16.0	33,701	4.54
cboModified	-8.5	19.5	42,581	5.74
fanin	-3.0	5.0	57,294	7.72
fanout	-8.0	16.0	33,701	4.54
wmc	-9.5	18.5	69,918	9.42
dit	-0.5	3.5	20,401	2.75
noc	0.0	0.0	28,225	3.80
rfc	-15.0	25.0	56,150	7.57
lcom	-6.0	10.0	119,210	16.07
loc	-41.0	87.0	69,575	9.38
totalMethodsQty	-5.0	11.0	63,883	8.61
totalFieldsQty	-4.5	7.5	51,746	6.97
nosi	-1.5	2.5	75,774	10.21
returnQty	-3.0	5.0	93,119	12.55
loopQty	0.0	0.0	109,982	14.82

Değişken	Alt Sınır	Üst Sınır	Outlier Sayısı	Oran (%)
comparisonsQty	0.0	0.0	173,364	23.37
variablesQty	-9.0	15.0	66,315	8.94
maxNestedBlocksQty	-1.5	2.5	54,323	7.32
uniqueWordsQty	-36.0	84.0	51,075	6.88

Yorum: Kod metrikleri veri setlerinde yüksek outlier oranları beklenen bir durumdur. Yazılım projelerinde az sayıda "God Class" veya aşırı karmaşık sınıflar, metrik değerlerini önemli ölçüde artırabilmektedir. Özellikle **comparisonsQty** (%23.37), **lcom** (%16.07), **loopQty** (%14.82) ve **returnQty** (%12.55) değişkenlerinde yüksek outlier oranları gözlemlenmektedir. Bu outlier'lar veri hatası değil, yazılım mühendisliğindeki doğal karmaşıklık varyasyonunu yansıtmaktadır.

9.4 Feature Scaling Gereksinimi

Değişken	Min	Max	Aralık	Std
cbo	0	192	192	5.8931
cboModified	0	471	471	7.4942
fanin	0	469	469	3.8387
fanout	0	192	192	5.8932
wmc	0	666	666	14.9835
dit	1	75	74	0.8218
noc	0	25	25	0.8426
rfc	0	237	237	14.227
lcom	0	221445	221445	1504.0433
loc	1	6667	6666	87.9248
totalMethodsQty	0	666	666	8.8134
totalFieldsQty	0	149	149	4.776
nosi	0	604	604	4.6066
returnQty	0	666	666	7.8062
loopQty	0	77	77	1.8194
comparisonsQty	0	153	153	3.6482
variablesQty	0	369	369	11.3463
maxNestedBlocksQty	0	14	14	1.1038
uniqueWordsQty	0	2866	2866	44.8212

- **Scaling gerekli mi?** Evet

Değişkenler arasında çok büyük ölçek farklılıkları bulunmaktadır (ör: `lcom` aralığı 221,445 iken `maxNestedBlocksQty` aralığı 14). Makine öğrenmesi modelleri öncesinde **RobustScaler** (outlier'lar nedeniyle) veya **StandardScaler** ile ölçeklendirme yapılması önerilir.

10. Sonuç ve Akademik Çıkarımlar (Conclusion)

10.1 Genel Değerlendirme

Bu analiz kapsamında, Code Metrics Dataset (SoftwareProjectStructure) veri seti detaylı olarak incelenmiştir. Veri seti, Java projelerindeki sınıf düzeyinde nesne yönelimli tasarım metriklerini içermekte olup, yazılım refactoring ihtiyacının tahmin edilmesi için zengin bir kaynak sunmaktadır.

10.2 Temel Bulgular


1. **Veri Kalitesi:** Veri setinde `tcc` ve `lcc` sütunlarında %32 oranında eksik değer bulunmakta olup, diğer sütunlarda eksik veri yoktur. Tekrarlayan kayıt bulunmamaktadır.
2. **Sınıf Dengesi:** Hedef değişken (`refactoring`) dengeli dağılım göstermektedir (1.04:1 oranı). SMOTE gibi yeniden örnekleme tekniklerine ihtiyaç duyulmamaktadır.
3. **Korelasyon Yapısı:** `cbo` ve `fanout` tam korelasyon (1.0) göstermektedir; bu iki değişkenden biri çıkarılmalıdır. `wmc`, `loc`, `totalMethodsQty` ve `returnQty` arasında güçlü korelasyonlar bulunmaktadır.
4. **Multicollinearity:** `cbo`-`fanout` çifti aşırı multicollinearity göstermektedir ($VIF \approx 189K$). `wmc` ($VIF=19.24$) ve `loc` ($VIF=9.83$) da yüksek VIF değerlerine sahiptir.
5. **Boyut İndirgeme:** PCA analizi, ilk bileşenin varyansın %43.59'unu açıkladığını göstermektedir. %95 varyans için 11 bileşen (18 üzerinden) yeterlidir.
6. **Outlier Yapısı:** Kod metriklerinde doğal olarak yüksek outlier oranları gözlemlenmektedir. Bu, yazılım projelerindeki karmaşıklık dağılımının doğal bir yansımasıdır.

10.3 Yazılım Test Optimizasyonu Perspektifi

- **Refactoring Tahmini:** Bu veri seti, yazılım sınıflarının refactoring ihtiyacının otomatik tahmin edilmesi için sınıflandırma modelleri (Random Forest, XGBoost, SVM) ile kullanılabilir.
- **Feature Selection:** `cbo`/`fanout` çiftinden birinin çıkarılması ve $VIF > 10$ olan değişkenlerin yeniden değerlendirilmesi önerilir. ANOVA sonuçlarına göre `cboModified`, `cbo`, `maxNestedBlocksQty`, `comparisonsQty` ve `wmc` en ayırt edici metriklerdir.
- **Test Önceliklendirme:** Kod metrikleri, yazılım test süreçlerinde hangi modüllerin öncelikli test edilmesi gerektiğini belirlemek için yapay zeka modelleriyle entegre edilebilir.
- **Kod Kalitesi İzleme:** CK metrikleri, CI/CD pipeline'larına entegre edilerek sürekli kod kalitesi izleme ve otomatik refactoring önerisi sistemleri kurulabilir.

10.4 NonTrivial vs Trivial Karşılaştırma

NonTrivial vs Trivial - Anahtar Metrik Ortalamaları



NonTrivial refactoring örnekleri, Trivial örneklere kıyasla genel olarak benzer metrik dağılımları sergilemektedir. Bu durum, refactoring türünün (trivial/non-trivial) metrik değerlerinden çok daha fazla bağlamsal bilgiye dayandığını düşündürmektedir.

Ödev Maddeleri Karşılama Tablosu

Madde	Başlık	Rapordaki Bölüm	Karşılandı?
1.1	Veri Seti Dosya Yapısı	Bölüm 1, 2.1	☒
1.2	Veri Boyutu (satır, sütun, tipler)	Bölüm 2.2, 2.3	☒
2	Temel İstatistik (ort, medyan, std, min/max, skew, kurt)	Bölüm 3	☒
3	Dağılım (histogram, boxplot, outlier)	Bölüm 4	☒
4.1	Korelasyon Analizi	Bölüm 6.1, 6.2	☒
4.2	Chi-Square (Kategorik)	Bölüm 6.3	☒
4.3	Sayısal – Hedef Analizi	Bölüm 6.5	☒
5	Sınıf Dengesi (imbalance, SMOTE)	Bölüm 5	☒
6	PCA Analizi	Bölüm 8	☒
7	Multicollinearity (VIF)	Bölüm 7	☒
8	Veri Kalitesi (missing, duplicate, gürültü, scaling)	Bölüm 9	☒
9	Rapor Formatı (akademik başlıklar)	Tüm rapor	☒
10	Değerlendirme Kriterleri	Bu tablo	☒