

Software Quality Attributes Dataset - Kapsamlı Analiz Raporu

Ders: Yazılım Test Sürecinin Optimizasyonu İçin Yapay Zeka Yöntemleri

1. Veri Seti Tanımı (Dataset Description)

Bu veri seti, 10 büyük ölçekli açık kaynak Java projesinin yazılım kalite niteliklerini (quality attributes) ve kod kokusu (code smell) metriklerini içermektedir. Veriler 2016-2021 yılları arasında altı farklı sürüm için toplanmış olup, sınıf düzeyinde nesne yönelimli tasarım metrikleri, paket düzeyinde bağımlılık ölçümleri ve God Class tespiti bilgilerini kapsamaktadır.

- Kaynak:** Kaggle - Software Quality Attributes Dataset
- Dosya Formatı:** CSV
- Toplam Veri Boyutu:** ~1,268 MB (1.24 GB)
- Ana Analiz Dosyası:** class_level_quality_code_smell_mdi.csv (57.32 MB)
- Toplam Gözlem Sayısı:** 190,707
- Özellik Sayısı:** 51

Analiz Edilen Projeler

#	Proje	Repository	Commits	Stars
1	Spring Framework	spring-projects/spring-framework	22,208	41,400
2	JUnit 5	junit-team/junit5	6,621	4,400
3	Apache Kafka	apache/kafka	8,590	18,000
4	Apache Lucene-Solr	apache/lucene-solr	34,789	4,100
5	Dropwizard	dropwizard/dropwizard	5,702	7,900
6	Checkstyle	checkstyle/checkstyle	9,922	5,800
7	Apache Hadoop	apache/hadoop	24,612	11,300
8	Selenium	SeleniumHQ/selenium	26,532	19,800
9	Apache Skywalking	apache/skywalking	6,242	16,100
10	Signal Android	signalapp/Signal-Android	7,015	19,800

2. Yapısal Analiz (Structural Analysis)

2.1 Dosya Yapısı

Veri seti aşağıdaki bileşenlerden oluşmaktadır:

Bileşen	Dosya Sayısı	Boyut (MB)	Açıklama
---------	--------------	------------	----------

Bileşen	Dosya Sayısı	Boyut (MB)	Açıklama
resulted/	1	57.32	Birleştirilmiş ana analiz dosyası
codesmells/csv/	60	1,038.62	Proje başına yıllık kod kokusu verileri
quality_attributes/	60	172.63	Proje başına yıllık kalite nitelikleri
attribute-details.csv	1	<0.01	47 metriğin açıklamaları
repositories.csv	1	<0.01	10 projenin bilgileri
versions.csv	1	0.01	Sürüm bilgileri
Toplam	124	~1,268	


2.2 Veri Boyutu ve Tipleri (Ana Dosya)

Metrik	Değer
Gözlem (satır) sayısı	190,707
Özellik (sütun) sayısı	51
float64 tipi sütun sayısı	42
object tipi sütun sayısı	6
int64 tipi sütun sayısı	3

2.3 Sütun Detayları (Anahtar Metrikler)

Sütun Adı	Veri Tipi	Açıklama
QualifiedName	object	Sınıfın tam nitelikli adı
Name	object	Sınıf adı
Complexity	object	Karmaşıklık seviyesi (low/medium/high)
Coupling	object	Bağımlılık seviyesi (low/medium/high)
Size	object	Boyut seviyesi (low/medium/high)
Lack of Cohesion	object	Uyum eksikliği seviyesi (low/medium/high)
CBO	float64	Coupling Between Object Classes
RFC	float64	Response For a Class
SRFC	float64	Simple Response For a Class
DIT	float64	Depth of Inheritance Tree
NOC	float64	Number of Children

Sütun Adı	Veri Tipi	Açıklama
WMC	float64	Weighted Method Count
LOC	float64	Lines of Code
CMLOC	float64	Class-Methods Lines of Code
NOF	float64	Number of Fields
NOM	float64	Number of Methods
LCOM	float64	Lack of Cohesion of Methods
LCAM	float64	Lack of Cohesion Among Methods
LTCC	float64	Lack of Tight Class Cohesion
ATFD	float64	Access to Foreign Data
SI	float64	Specialization Index
GodClass	int64	Hedef değişken (0/1)
ps_LOC / ps_WMC / ps_ATFD / ps_LTCC / ps_NOM	float64	Proje-seviye normalize skorlar
mdi_godclass	float64	MDI God Class olasılık skoru
filename	object	Proje-yıl tanımlayıcı



3. Betimleyici İstatistikler (Descriptive Statistics)

3.1 Sayısal Değişkenlerin Özet İstatistikleri

Değişken	Ortalama	Medyan	Std Sapma	Min	Max	Çarpıklık	Basıklık
----------	----------	--------	-----------	-----	-----	-----------	----------

Değişken	Ortalama	Medyan	Std Sapma	Min	Max	Çarpıklık	Basıklık
CBO	1.5391	0.0	4.7696	0.0	199.0	8.6542	143.5421
RFC	16.2904	1.0	68.507	0.0	4,185.0	16.2775	514.6213
SRFC	3.7349	0.0	12.9411	0.0	780.0	11.0311	275.5176
DIT	0.7521	0.0	1.1541	0.0	10.0	2.4925	8.7342
NOC	0.3068	0.0	2.5099	0.0	171.0	29.7688	1260.8151
WMC	6.7734	2.0	19.5985	0.0	1,262.0	17.8174	737.465
LOC	58.3015	20.0	309.3402	0.0	40,736.0	82.1504	8523.5161
CMLOC	20.5192	3.0	64.4645	0.0	4,113.0	15.0504	468.0889
NOF	1.0885	0.0	2.6566	0.0	76.0	6.4114	76.3037
NOSF	0.6704	0.0	5.485	0.0	772.0	66.228	7073.7692
NOM	3.1888	1.0	6.9281	0.0	349.0	9.0616	175.2475
NOSM	0.2733	0.0	2.1125	0.0	284.0	45.3543	4564.1002
LCOM	0.1449	0.0	0.3198	0.0	2.0	2.0965	3.4688
LCAM	0.1754	0.0	0.2551	0.0	0.97	1.0946	-0.2324
LTCC	0.1753	0.0	0.3463	0.0	1.0	1.6162	0.8468
ATFD	0.104	0.0	0.6007	0.0	41.0	16.1343	535.3342
SI	0.0496	0.0	0.3116	0.0	12.0	10.3537	166.2642
ps_LOC	0.2171	0.108	0.2669	0.0	1.0	1.8013	2.3402
ps_WMC	0.1459	0.0426	0.23	0.0	1.0	2.3611	5.2466
ps_ATFD	0.0232	0.0	0.0918	0.0	1.0	5.8275	43.4408
ps_LTCC	0.2568	0.0	0.434	0.0	1.0	1.1106	-0.7526
ps_NOM	0.1872	0.1111	0.2526	0.0	1.0	1.8213	2.7235
mdi_godclass	0.166	0.0594	0.2066	0.0	1.0	1.5375	1.7342

3.2 Çeyreklik Değerleri

Değişken	Q1	Q3	IQR
CBO	0.0	1.0	1.0
RFC	0.0	7.0	7.0
SRFC	0.0	2.0	2.0
DIT	0.0	1.0	1.0

Değişken	Q1	Q3	IQR
NOC	0.0	0.0	0.0
WMC	0.0	6.0	6.0
LOC	8.0	52.0	44.0
CMLOC	0.0	18.0	18.0
NOF	0.0	1.0	1.0
NOM	0.0	4.0	4.0
LCOM	0.0	0.0	0.0
LCAM	0.0	0.375	0.375
LTCC	0.0	0.0	0.0
ATFD	0.0	0.0	0.0
SI	0.0	0.0	0.0


Çarpıklık Yorumu: Tüm metrikler güçlü pozitif çarpıklık göstermektedir. Özellikle **LOC** (82.15), **NOSF** (66.23), **NOSM** (45.35) ve **NOC** (29.77) aşırı sağa çarpık dağılımlara sahiptir. Bu, büyük çoğunluk sınıfların küçük ve basit olduğunu, az sayıda karmaşık sınıfın metrikleri yukarı çektiğini göstermektedir.

Basıklık Yorumu: **LOC** (8523.52), **NOSF** (7073.77), **NOSM** (4564.10) gibi değişkenler aşırı sivri (leptokurtik) dağılımlara sahiptir. Bu, uç değerdeki "God Class" tarzı karmaşık sınıfların varlığına işaret etmektedir.

4. Dağılım Analizi (Distribution Analysis)


Her sayısal değişken için histogram ve boxplot grafikleri oluşturulmuştur.

4.1 CBO (Coupling Between Objects)




- **IQR Alt Sınır:** -1.5
- **IQR Üst Sınır:** 2.5
- **Outlier Sayısı:** 30,839 (%16.18)

4.2 RFC (Response For a Class)





- **IQR Alt Sınır:** -10.5
- **IQR Üst Sınır:** 17.5
- **Outlier Sayısı:** 27,608 (%14.48)

4.3 WMC (Weighted Method Count)





- **IQR Alt Sınır:** -9.0
- **IQR Üst Sınır:** 15.0
- **Outlier Sayısı:** 20,404 (%10.70)

4.4 LOC (Lines of Code)





- **IQR Alt Sınır:** -58.0
- **IQR Üst Sınır:** 118.0
- **Outlier Sayısı:** 20,580 (%10.79)

4.5 LCOM (Lack of Cohesion of Methods)




- **IQR Alt Sınır:** 0.0
- **IQR Üst Sınır:** 0.0
- **Outlier Sayısı:** 36,618 (%19.21)

4.6 LTCC (Lack of Tight Class Cohesion)




- **IQR Alt Sınır:** 0.0
- **IQR Üst Sınır:** 0.0
- **Outlier Sayısı:** 42,502 (%22.29)

4.7 ATFD (Access to Foreign Data)




- **IQR Alt Sınır:** 0.0
- **IQR Üst Sınır:** 0.0
- **Outlier Sayısı:** 11,384 (%5.97)

4.8 NOM (Number of Methods)




- **IQR Alt Sınır:** -6.0
- **IQR Üst Sınır:** 10.0
- **Outlier Sayısı:** 12,919 (%6.78)

4.9 DIT (Depth of Inheritance Tree)





- **IQR Alt Sınır:** -1.5
- **IQR Üst Sınır:** 2.5
- **Outlier Sayısı:** 13,172 (%6.91)


Genel Boxplot Karşılaştırması




Kategorik Değişken Dağılımları










5. Hedef Değişken Analizi (Target Variable Analysis)

Bu veri setinde hedef değişken **GodClass** olup, bir sınıfın "God Class" anti-pattern'ine sahip olup olmadığını belirten ikili sınıflandırma değişkenidir. God Class, aşırı büyük, karmaşık ve düşük uyumlu sınıfları tanımlar.


5.1 GodClass Sınıf Dağılımı



Sınıf	Frekans	Oran
Non-GodClass (0)	158,079	%82.89
GodClass (1)	32,628	%17.11


- **Çoğunluk sınıfı:** Non-GodClass (0) (%82.89)
- **Azınlık sınıfı:** GodClass (1) (%17.11)
- **Dengesizlik oranı:** 4.8449
- **Dengesizlik (Imbalance) var mı?** Evet
- **SMOTE gerekli mi?** Evet (azınlık sınıfı %17 oranında)

5.2 MDI GodClass Olasılık Skoru Dağılımı



MDI (Multiple Data Imputation) yöntemiyle hesaplanan God Class olasılık skoru 0-1 arasında dağılmaktadır. Ortalama skor 0.166 olup, çoğu sınıfın düşük God Class olasılığına sahip olduğu görülmektedir.

5.3 Proje Bazlı GodClass Oranı



Proje	GodClass Sayısı	Toplam Sınıf	GodClass Oranı
Checkstyle	630	2,551	%24.70
Dropwizard	700	3,226	%21.70
JUnit 5	514	2,479	%20.73


Proje	GodClass Sayısı	Toplam Sınıf	GodClass Oranı
Skywalking	2,090	10,092	%20.71
Signal Android	2,295	11,378	%20.17
Selenium	1,327	6,608	%20.08
Kafka	2,236	11,432	%19.56
Lucene-Solr	8,517	51,120	%16.66
Spring Framework	5,203	31,675	%16.43
Hadoop	9,116	60,146	%15.16

Yorum: Checkstyle (%24.70) ve Dropwizard (%21.70) projelerinde en yüksek God Class oranı gözlemlenirken, Hadoop (%15.16) ve Spring Framework (%16.43) en düşük oranlara sahiptir. Daha büyük projelerin (Hadoop, Spring) daha düşük God Class oranına sahip olması, iyi yapılandırılmış kod mimarisinin etkisini göstermektedir.

6. Korelasyon ve Bağımlılık Analizi (Correlation & Dependency Analysis)

6.1 Pearson Korelasyon Matrisi

Pearson Korelasyon Matrisi



6.2 En Yüksek Korelasyonlar

Değişken 1	Değişken 2	Korelasyon
WMC	WMC.1	1.0000
LOC	LOC.1	1.0000
WMC	CMLOC	0.9065
CMLOC	WMC.1	0.9065
CBO	SRFC	0.8289
SRFC	CMLOC	0.7675
RFC	SRFC	0.7167
SRFC	WMC	0.7037
CMLOC	NOM	0.6921
SRFC	ATFD	0.6888

Değişken 1	Değişken 2	Korelasyon
WMC	NOM	0.6810
CBO	RFC	0.6792
SRFC	NOM	0.6520


Yorum: WMC ve WMC.1 ile LOC ve LOC.1 arasında tam korelasyon (1.0) bulunmaktadır; bunlar aynı metriğin farklı kaynaklardan gelen tekrarlarıdır. WMC-CMLOC (0.91) arasında çok güçlü korelasyon mevcuttur; her ikisi de sınıf karmaşıklığını ölçmektedir. CBO-SRFC (0.83) bağımlılık metrikleri arasındaki güçlü ilişkiyi göstermektedir.


6.3 Chi-Square Bağımsızlık Testleri (Kategorik Değişkenler)

Değişken 1	Değişken 2	χ^2	p-değeri	Cramér's V	Anlamli?
Complexity	GodClass	2,590.46	0.000000	0.1165	Evet
Coupling	GodClass	2,445.26	0.000000	0.1132	Evet
Size	GodClass	11,112.49	0.000000	0.2414	Evet
Lack of Cohesion	GodClass	3,292.16	0.000000	0.1314	Evet

Yorum: Tüm kategorik kalite nitelikleri, God Class hedef değişkeni ile istatistiksel olarak anlamlı ilişkiye sahiptir ($p < 0.001$). Size kategorisi en güçlü ilişkiyi göstermektedir ($V = 0.2414$), bu da sınıf boyutunun God Class tespitinde en önemli kategorik gösterge olduğuna işaret etmektedir.

6.4 Çapraz Tablolar






6.5 ANOVA Testi (Sayısal ~ GodClass)

Değişken	F-İstatistik	p-değeri	Anlamlı?
CBO	1,083.17	0.000000	Evet
RFC	1,184.41	0.000000	Evet
SRFC	3,417.59	0.000000	Evet
DIT	163.12	0.000000	Evet
NOC	1.15	0.283094	Hayır
WMC	4,889.77	0.000000	Evet
LOC	1,873.72	0.000000	Evet
CMLOC	4,740.42	0.000000	Evet
NOF	2,705.44	0.000000	Evet
NOSF	183.71	0.000000	Evet
NOM	2,980.87	0.000000	Evet
NOSM	1,044.72	0.000000	Evet
LCOM	1,626.97	0.000000	Evet
LCAM	687.23	0.000000	Evet
LTCC	1,280.40	0.000000	Evet
ATFD	1,288.76	0.000000	Evet


Değişken	F-İstatistik	p-değeri	Anlamlı?
SI	13.45	0.000245	Evet



Yorum: **NOC** hariç tüm sayısal metrikler God Class ile istatistiksel olarak anlamlı farklılık göstermektedir. En yüksek F değerlerine sahip metrikler: **WMC** ($F=4,889.77$), **CMLOC** ($F=4,740.42$), **SRFC** ($F=3,417.59$), **NOM** ($F=2,980.87$) ve **NOF** ($F=2,705.44$). Bu metrikler God Class tespitinde en ayırt edici özelliklerdir.

7. Çoklu Doğrusal Bağlantı Analizi (Multicollinearity)

VIF (Variance Inflation Factor) değerleri hesaplanmıştır. $VIF > 10$ ciddi, $VIF > 5$ orta düzey multicollinearity anlamına gelir.




Değişken	VIF	Ciddi MC? (>10)	Orta MC? (>5)
CBO	3.54	Hayır	Hayır
RFC	2.16	Hayır	Hayır
SRFC	5.85	Hayır	Evet
DIT	1.36	Hayır	Hayır
NOC	1.01	Hayır	Hayır
WMC	5.54	Hayır	Evet
LOC	1.14	Hayır	Hayır
CMLOC	7.35	Hayır	Evet
NOF	1.94	Hayır	Hayır
NOSF	1.07	Hayır	Hayır
NOM	2.68	Hayır	Hayır
NOSM	1.31	Hayır	Hayır
LCOM	2.13	Hayır	Hayır
LCAM	2.51	Hayır	Hayır
LTCC	1.76	Hayır	Hayır
ATFD	1.92	Hayır	Hayır
SI	1.14	Hayır	Hayır

Sonuç: Hiçbir değişkende ciddi multicollinearity ($VIF > 10$) tespit edilmemiştir. **CMLOC** ($VIF=7.35$), **SRFC** ($VIF=5.85$) ve **WMC** ($VIF=5.54$) orta düzey multicollinearity göstermektedir. Bu değişkenler sınıf karmaşıklığı ile ilgili metrikleri temsil etmekte olup, aralarındaki korelasyon beklenen bir durumdur.

8. Boyut Analizi (Dimensionality Analysis)

8.1 PCA (Principal Component Analysis)




Bileşen	Açıklanan Varyans (%)	Kümülatif (%)
PC1	35.94	35.94
PC2	9.25	45.19
PC3	8.43	53.62
PC4	6.47	60.09
PC5	5.93	66.02
PC6	5.71	71.74
PC7	5.36	77.09
PC8	4.34	81.44
PC9	3.86	85.29
PC10	3.10	88.39
PC11	2.75	91.14
PC12	2.26	93.40
PC13	1.99	95.39

- **%85 varyans için gereken bileşen sayısı: 9**
- **%90 varyans için gereken bileşen sayısı: 11**
- **%95 varyans için gereken bileşen sayısı: 13**

Yorum: İlk bileşen (PC1) varyansın %35.94'ünü açıklamakta olup, sınıf büyüklüğü ve karmaşıklık metriklerinin ortak faktörünü temsil etmektedir. 17 değişkenden %85 varyansı açıklamak için 9 bileşen yeterlidir; bu, yaklaşık %47 boyut indirgeme fırsatı sunmaktadır.

8.2 PCA 2D Scatter Plot



9. Veri Kalitesi Değerlendirmesi (Data Quality Assessment)

9.1 Eksik Veri (Missing Values)

Sınıf Düzeyinde Metrikler (%0.03 eksik):

Sütun	Eksik Değer	Oran (%)
CBO, RFC, SRFC, DIT, NOC, WMC, LOC, CMLOC, NOF, NOSF, NOM, NOSM, LCOM, LCAM, LTCC, ATFD, SI, LOC.1, WMC.1	60 (her biri)	%0.03
NORM	1,079	%0.57
Name	66	%0.03

Tamamen Boş Sütunlar (%100 eksik) - Paket ve Metot Düzeyindeki Metrikler:

Sütun	Açıklama
Coverage, #(C&I), #C, #I	Paket kapsamı metrikleri

Sütun	Açıklama
AC, EC, Abs, Ins, ND	Paket bağımlılık metrikleri
Coverage.1, MCC, NBD, LOC.2, #Pa, #MC, #AF	Metot düzeyi metrikleri

Yorum: Ana kalite metrikleri (sınıf düzeyi) neredeyse eksiksizdir (%0.03 eksik). Ancak paket ve metot düzeyindeki 14 sütun tamamen boştur; bu sütunlar ana birleştirilmiş dosyaya dahil edilmiş ancak bu düzeyde veri toplanmamıştır.

9.2 Tekrarlayan Kayıtlar (Duplicates)

- **Toplam tekrarlayan satır:** 0
- **Tekrarlama oranı:** %0.0

9.3 Gürültülü Veri ve Anormal Değerler

IQR yöntemiyle tespit edilen outlier'lar:

Değişken	Alt Sınır	Üst Sınır	Outlier Sayısı	Oran (%)
CBO	-1.5	2.5	30,839	16.18
RFC	-10.5	17.5	27,608	14.48
SRFC	-3.0	5.0	29,099	15.26
DIT	-1.5	2.5	13,172	6.91
NOC	0.0	0.0	18,106	9.50
WMC	-9.0	15.0	20,404	10.70
LOC	-58.0	118.0	20,580	10.79
CMLOC	-27.0	45.0	21,124	11.08
NOF	-1.5	2.5	25,435	13.34
NOSF	0.0	0.0	34,379	18.03
NOM	-6.0	10.0	12,919	6.78
NOSM	0.0	0.0	15,800	8.29
LCOM	0.0	0.0	36,618	19.21
LCAM	-0.56	0.94	30	0.02
LTCC	0.0	0.0	42,502	22.29
ATFD	0.0	0.0	11,384	5.97
SI	0.0	0.0	8,542	4.48

Yorum: Yazılım kalite metrikleri doğası gereği sağa çarpık dağılıma sahiptir. **LTCC** (%22.29), **LCOM** (%19.21) ve **NOSF** (%18.03) değişkenlerinde yüksek outlier oranları gözlemlenmektedir. Bu outlier'lar, God Class veya

karmaşık sınıfların doğal varlığını yansıtmaktadır.

9.4 Feature Scaling Gereksinimi

Değişken	Min	Max	Aralık	Std
CBO	0.0	199.0	199.0	4.7696
RFC	0.0	4,185.0	4,185.0	68.507
SRFC	0.0	780.0	780.0	12.9411
DIT	0.0	10.0	10.0	1.1541
NOC	0.0	171.0	171.0	2.5099
WMC	0.0	1,262.0	1,262.0	19.5985
LOC	0.0	40,736.0	40,736.0	309.3402
CMLOC	0.0	4,113.0	4,113.0	64.4645
NOF	0.0	76.0	76.0	2.6566
NOM	0.0	349.0	349.0	6.9281
LCOM	0.0	2.0	2.0	0.3198
LCAM	0.0	0.97	0.97	0.2551
LTCC	0.0	1.0	1.0	0.3463
ATFD	0.0	41.0	41.0	0.6007
SI	0.0	12.0	12.0	0.3116

- **Scaling gerekli mi?** Evet

Değişkenler arasında çok büyük ölçek farklılıkları bulunmaktadır (ör: **LOC** aralığı 40,736 iken **LCOM** aralığı 2.0). Makine öğrenmesi modelleri öncesinde **RobustScaler** (yüksek outlier oranları nedeniyle) veya **StandardScaler** ile ölçeklendirme yapılması önerilir.

10. Sonuç ve Akademik Çıkarımlar (Conclusion)

10.1 Genel Değerlendirme

Bu analiz kapsamında, 10 büyük ölçekli açık kaynak Java projesinden toplanan yazılım kalite nitelikleri veri seti detaylı olarak incelenmiştir. Veri seti, sınıf düzeyinde CK metrikleri, uyum/bağımlılık ölçümleri ve God Class tespiti bilgilerini içermektedir.

10.2 Temel Bulgular

1. **Veri Kalitesi:** Sınıf düzeyindeki ana metrikler neredeyse eksiksizdir (%0.03). Paket ve metot düzeyindeki 14 sütun tamamen boş olup, analiz dışı bırakılmıştır.

2. **Sınıf Dengesi:** God Class hedef değışkeni belirgin dengesizlik göstermektedir (4.84:1 oranı, %17.11 GodClass). SMOTE veya ADASYN gibi tekniklerle dengeleme yapılması önerilmektedir.
3. **Korelasyon Yapısı:** **WMC-CMLOC** (0.91), **CBO-SRFC** (0.83) arasında güçlü korelasyonlar bulunmaktadır. **WMC/WMC.1** ve **LOC/LOC.1** çiftleri aynı bilgiyi taşımaktadır.
4. **Multicollinearity:** Ciddi multicollinearity tespit edilmemiştir (tüm VIF < 10). Orta düzeyde **CMLOC** (7.35), **SRFC** (5.85) ve **WMC** (5.54) bulunmaktadır.
5. **Boyut İndirgeme:** PCA'da ilk bileşen varyansın %35.94'ünü açıklamaktadır. %85 varyans için 9 bileşen (17 üzerinden) yeterlidir.
6. **ANOVA Sonuçları:** **NOC** hariç tüm metrikler God Class ile anlamlı farklılık göstermektedir. En güçlü ayırt ediciler: **WMC**, **CMLOC**, **SRFC**, **NOM**, **NOF**.

10.3 Yazılım Test Optimizasyonu Perspektifi

- **God Class Tespiti:** Bu veri seti, God Class anti-pattern'inin otomatik tespiti için sınıflandırma modelleri (Random Forest, XGBoost, SMOTE+SVM) ile kullanılabilir.
- **Kod Kalitesi İzleme:** CK metrikleri ve kalite nitelikleri, CI/CD pipeline'larına entegre edilerek sürekli kod kalitesi izleme sistemleri oluşturulabilir.
- **Test Önceliklendirme:** God Class olasılığı yüksek sınıflar, test süreçlerinde öncelikli olarak ele alınabilir. **mdi_godclass** skoru, risk tabanlı test stratejilerinde kullanılabilir.
- **Refactoring Önerisi:** Yüksek **WMC**, **LOC** ve **ATFD** değerlerine sahip sınıflar için otomatik refactoring önerileri üretilebilir.
- **Proje Karşılaştırması:** Farklı projelerdeki God Class oranları, yazılım mimarisi kalitesinin karşılaştırmalı analizi için kullanılabilir.

Ödev Maddeleri Karşılama Tablosu

Madde	Başlık	Rapordaki Bölüm	Karşılandı?
1.1	Veri Seti Dosya Yapısı	Bölüm 1, 2.1	☑
1.2	Veri Boyutu (satır, sütun, tipler)	Bölüm 2.2, 2.3	☑
2	Temel İstatistik (ort, medyan, std, min/max, skew, kurt)	Bölüm 3	☑
3	Dağılım (histogram, boxplot, outlier)	Bölüm 4	☑
4.1	Korelasyon Analizi	Bölüm 6.1, 6.2	☑
4.2	Chi-Square (Kategorik)	Bölüm 6.3	☑
4.3	Sayısal – Hedef Analizi	Bölüm 6.5	☑
5	Sınıf Dengesi (imbalance, SMOTE)	Bölüm 5	☑
6	PCA Analizi	Bölüm 8	☑

Madde	Başlık	Rapordaki Bölüm	Karşılandı?
7	Multicollinearity (VIF)	Bölüm 7	☒
8	Veri Kalitesi (missing, duplicate, gürültü, scaling)	Bölüm 9	☒
9	Rapor Formatı (akademik başlıklar)	Tüm rapor	☒
10	Değerlendirme Kriterleri	Bu tablo	☒