CI/CD Pipeline vs. Software Observability Veri Setleri — Karşılaştırmalı Analiz Raporu

Ders: Yazılım Test Sürecinin Optimizasyonu İçin Yapay Zeka Yöntemleri
Tarih: 2026-03-04
Hazırlayan: Çağatay Üresin

---

1. Giriş

Bu rapor, yazılım test süreçlerinin yapay zeka ile optimizasyonu dersi kapsamında incelenen iki farklı veri setinin ayrıntılı karşılaştırmasını sunmaktadır. İlk veri seti CI/CD (Continuous Integration / Continuous Deployment) pipeline hata loglarını, ikinci veri seti ise Software Observability (yazılım gözlemlenebilirliği) log verilerini içermektedir. Her iki veri seti de yazılım geliştirme ve operasyon süreçlerinin farklı yönlerini temsil etmektedir; bu karşılaştırma, veri setlerinin yapısal, istatistiksel ve analitik açıdan farklılıklarını ve benzerliklerini ortaya koymayı amaçlamaktadır.

---

2. Yapısal Karşılaştırma

2.1 Genel Boyut ve Format

Metrik	CI/CD Pipeline	Software Observability
Toplam Dosya Sayısı	1	13
Dosya Formatları	CSV	TXT, JSON
Toplam Veri Boyutu	15.33 MB	3,170.5 MB (3.10 GB)
Toplam Satır Sayısı	45,000	20,834,765
Bellek Kullanımı	50.88 MB	Çoklu DataFrame
Kaynak	Kaggle (tek dosya)	3 alt kaynak (BHRAMARI, OBSERVER, Utility)

İki veri seti arasındaki en belirgin fark veri hacmindedir. Observability veri seti, CI/CD veri setinden yaklaşık **207 kat** daha büyük dosya boyutuna ve **463 kat** daha fazla satır sayısına sahiptir. Bu durum, gözlemlenebilirlik sistemlerinin ürettiği log hacminin CI/CD pipeline loglarına kıyasla çok daha yoğun olduğunu yansıtmaktadır.

2.2 Veri Yapısı Karmaşıklığı

Özellik	CI/CD Pipeline	Software Observability
Sütun Sayısı	25	14 (Log) + 13 (Observer)

Özellik	CI/CD Pipeline	Software Observability
Alt Veri Kaynağı	Yok (tek homojen dosya)	3 farklı kaynak
Veri Tipi Çeşitliliği	object(15), int64(5), bool(3), datetime64(1), float64(1)	object, int64, float64 (bool yok, datetime yok)
Homojenlik	Yüksek — tek CSV, tek şema	Düşük — çoklu format, çoklu şema

CI/CD veri seti yapısal olarak homojen ve tek bir şemaya sahipken, Observability veri seti heterojen bir yapıdadır. Observability verisinde yapılandırılmış (structured), yarı-yapılandırılmış (semi-structured) ve yapılandırılmamış (unstructured) loglar bir arada bulunmaktadır. Bu farklılık, Observability veri setinin ön işleme (preprocessing) aşamasının çok daha karmaşık olacağı anlamına gelmektedir.

2.3 Özellik Alanları

CI/CD Pipeline veri seti yazılım geliştirme sürecinin teknik altyapısına odaklanmaktadır: pipeline kimliği, CI aracı (Jenkins, GitLab CI, GitHub Actions vb.), build/test/deploy süreleri, hata türleri, ciddiyet seviyeleri, sistem kaynakları (CPU, bellek) ve operasyonel metrikler (retry, rollback, incident).

Observability veri seti ise çalışma zamanı (runtime) gözlemlenebilirliğine odaklanmaktadır: log mesajları, log seviyeleri (INFO, ERROR, WARN vb.), servis adları, log formatları, UI etkileşim kayıtları (action, tag, URL, domain) ve mesaj uzunlukları.

---

3. Betimleyici İstatistikler Karşılaştırması

3.1 Sayısal Değişken Dağılım Karakteristikleri

CI/CD Pipeline — Sayısal Değişkenler:

Değişken	Ortalama	Std Sapma	Çarpıklık	Basıklık
build_duration_sec	1,820.65	1,029.02	-0.0016	-1.1984
test_duration_sec	1,207.79	689.38	-0.0043	-1.1990
deploy_duration_sec	896.74	521.46	0.0086	-1.2025
cpu_usage_pct	52.50	24.52	0.0015	-1.1957
memory_usage_mb	16,551.88	9,356.07	-0.0133	-1.1941
retry_count	2.51	1.71	-0.0141	-1.2686

Observability — Sayısal Değişkenler:

Değişken	Ortalama	Std Sapma	Çarpıklık	Basıklık
msg_len	65.71	37.55	1.1376	0.7730
level_value	5,623.35	12,225.90	1.9034	2.0361
index (Observer)	43,670.52	25,236.67	0.0000	-1.2000
id_len (Observer)	13.00	0.17	-73.9787	5,702.90
has_xpath (Observer)	1.00	0.01	-147.8284	21,851.75

3.2 Dağılım Karakteristikleri Yorumu

İki veri seti arasında dağılım profilleri açısından çarpıcı farklılıklar bulunmaktadır:

Simetri Açısından: CI/CD veri setindeki tüm sayısal değişkenler neredeyse mükemmel simetrik dağılıma sahiptir (çarpıklık değerleri ≈ 0). Bu durum, verinin sentetik olarak üretildiğine veya uniform dağılımdan örneklendiğine güçlü bir işaret oluşturmaktadır. Observability veri setinde ise msg_len (çarpıklık: 1.14) ve level_value (çarpıklık: 1.90) sağa çarpık dağılımlar göstermektedir; bu, gerçek dünya log verilerinin doğal karakteristiğiyle daha uyumludur.

Basıklık Açısından: CI/CD değişkenlerinin tamamı negatif basıklık (platikurtik, ≈ -1.2) göstermektedir; bu, uniform benzeri bir dağılımı işaret eder. Observability verisinde ise id_len ve has_xpath aşırı yüksek basıklık değerleri sergiler (leptokurtik); bu değişkenler neredeyse sabit değerlerdir ve varyansları ihmal edilebilir düzeydedir.

Sonuç: CI/CD veri setinin dağılım profili, kontrollü bir ortamda üretilmiş sentetik veriye işaret ederken, Observability veri seti gerçek dünya log verilerinin tipik asimetrik ve heterojen yapısını yansıtmaktadır.

---

4. Dağılım Analizi Karşılaştırması

4.1 Outlier Profili

Metrik	CI/CD Pipeline	Software Observability
Toplam Outlier Sayısı	0 (tüm değişkenlerde)	msg_len: 26,269 (%3.3), level_value: 150,000 (%18.8)
Outlier Oranı	%0.0	%3.3 – %18.8 (değişkene göre)
IQR Genişliği	Geniş (verinin tamamını kapsar)	Dar (özellikle level_value'da IQR=0)

CI/CD veri setinde hiçbir değişkende IQR yöntemiyle outlier tespit edilmemiştir. Bu, verilerin belirli bir aralıkta uniform olarak dağıtıldığını ve sınır değerlerin IQR kapsamında kaldığını göstermektedir. Observability veri setinde ise özellikle level_value değişkeninde %18.8 oranında outlier mevcuttur; bu değişkenin IQR'si 0

olduğundan (Q1=Q3=0), sıfır olmayan tüm değerler outlier olarak sınıflandırılmıştır. Bu durum, level_value'nun çoğunlukla 0 değerine sahip olduğu bir ikili yapıda olmasından kaynaklanmaktadır.

4.2 Kategorik Değişken Dağılımları

CI/CD Pipeline:

Kategorik değişkenler genel olarak dengeli dağılım göstermektedir. Örneğin, severity sınıfları (%24.9–%25.3 aralığında), failure_stage sınıfları (%33.1–%33.5 aralığında) ve failure_type sınıfları (%9.6–%10.3 aralığında) neredeyse eşit dağılmıştır. CI aracı, branch, OS ve cloud_provider değişkenleri de benzer şekilde dengeli dağılıma sahiptir.

Observability:

Log seviyesi dağılımı belirgin bir dengesizlik göstermektedir: INFO (%43.9), ERROR (%26.2), WARN (%23.2), CRITICAL (%3.1), DEBUG (%2.3), TRACE (%1.3). Bu dağılım, gerçek dünya sistemlerinde INFO seviyesinin baskın olduğu doğal log üretim paternini yansıtmaktadır. Observer verileri ise action ve tag bazında dengeli dağılım sergilemektedir.

---

5. Hedef Değişken ve Sınıf Dengesi Karşılaştırması

Metrik	CI/CD Pipeline	Software Observability
Potansiyel Hedef Değişken	severity, failure_stage, failure_type	log_level
Çoğunluk Sınıfı	LOW (%25.25)	INFO (%43.9)
Azınlık Sınıfı	MEDIUM (%24.87)	TRACE (%1.3)
Dengesizlik Oranı	1.0153 (severity)	34.71
Imbalance Var mı?	Hayır	Evet
SMOTE Gerekli mi?	Hayır	Evet

Bu karşılaştırma, iki veri seti arasındaki en kritik farklardan birini ortaya koymaktadır. CI/CD veri setinde hedef değişkenler mükemmele yakın dengeli dağılıma sahiptir; bu, sınıflandırma modelleri için doğrudan kullanılabilirlik anlamına gelir. Observability veri setinde ise 34.71 oranında ciddi bir sınıf dengesizliği mevcuttur. Bu dengesizlik, makine öğrenmesi modellerinin eğitiminde SMOTE, class weighting veya cost-sensitive learning gibi tekniklerin zorunlu olarak uygulanması gerektiğini göstermektedir.

Gerçek dünya perspektifinden bakıldığında, Observability veri setindeki dengesizlik daha gerçekçidir: üretim sistemlerinde CRITICAL ve TRACE seviyesindeki loglar doğal olarak çok daha azdır.

---

6. Korelasyon ve Bağımlılık Analizi Karşılaştırması

6.1 Korelasyon Yapısı

CI/CD Pipeline:

Tüm sayısal değişkenler arasındaki korelasyonlar neredeyse sıfırdır (en yüksek: memory_usage_mb ↔ retry_count = -0.0094). Bu, değişkenlerin birbirinden tamamen bağımsız olarak üretildiğini göstermektedir. Gerçek dünya CI/CD ortamlarında build süresi ile CPU kullanımı veya memory kullanımı ile deploy süresi arasında anlamlı korelasyonlar beklenir; bu beklentinin karşılanmaması, veri setinin sentetik doğasını teyit etmektedir.

Observability:

Anlamlı ve güçlü korelasyonlar tespit edilmiştir: level_value ↔ has_userId (r=0.9575), level_value ↔ has_error (r=0.7237), has_userId ↔ has_error (r=0.5358). Bu korelasyonlar, log seviyesi yükseldikçe (WARN → ERROR → CRITICAL) kullanıcı bilgisi ve hata detayı içerme olasılığının arttığı anlamlı bir ilişkiyi yansıtmaktadır.

6.2 Chi-Square Sonuçları

Veri Seti	Anlamlı İlişki Sayısı	Toplam Test	En Yüksek Cramér's V
CI/CD	1 (ci_tool ↔ os)	15	0.0157
Observability	3 (tümü anlamlı)	3	0.4642

CI/CD veri setinde kategorik değişkenler arasında neredeyse hiçbir anlamlı ilişki bulunmazken (sadece ci_tool ↔ os düşük etki büyüklüğüyle anlamlı), Observability veri setinde tüm test edilen çiftlerde yüksek anlamlılık ve yüksek etki büyüklüğü (Cramér's V > 0.30) tespit edilmiştir. Bu, Observability verisinin değişkenler arası daha zengin bir yapısal ilişki barındırdığını göstermektedir.

6.3 ANOVA Sonuçları

CI/CD Pipeline: Hiçbir sayısal değişken severity grupları arasında anlamlı farklılık göstermemiştir (tüm p > 0.05). Bu, ciddiyet seviyesinin sayısal metriklerden (süre, CPU, bellek) bağımsız olarak atandığını göstermektedir.

Observability: msg_len ~ log_level ilişkisinde çok güçlü anlamlı fark tespit edilmiştir (F=14,071.93, p≈0). Log seviyesi yükseldikçe mesaj uzunluğunun belirgin şekilde değiştiği, özellikle ERROR ve CRITICAL mesajlarının daha uzun olma eğiliminde olduğu gözlemlenmiştir.

---

7. Multicollinearity Karşılaştırması

Metrik	CI/CD Pipeline	Software Observability
En Yüksek VIF	1.0001	48.1624 (level_value)
Ciddi MC (VIF > 10)	Yok	Evet (level_value, has_userId)
Orta MC (VIF > 5)	Yok	Evet (has_error: 5.67)
Önerilen Aksiyon	Gerekli değil	level_value veya has_userId çıkarılmalı

CI/CD veri setinde tüm VIF değerleri 1.0'a eşittir; bu, değişkenler arasında doğrusal bağıntı olmadığını doğrular. Observability veri setinde ise level_value (VIF=48.16) ve has_userId (VIF=32.19) arasında ciddi multicollinearity tespit edilmiştir. Bu iki değişkenin Pearson korelasyonu 0.9575 olduğundan, model eğitiminde birinin çıkarılması veya PCA ile boyut indirgeme yapılması gerekmektedir.

---

8. Boyut Analizi (PCA) Karşılaştırması

8.1 Varyans Dağılımı

Eşik	CI/CD (Gerekli Bileşen)	Observability (Gerekli Bileşen)
%85	6 (tümü)	4
%90	6 (tümü)	5
%95	6 (tümü)	5

8.2 Bireysel Bileşen Varyansları

CI/CD: PC1=%16.9, PC2=%16.8, PC3=%16.7, PC4=%16.6, PC5=%16.6, PC6=%16.5

Observability: PC1=%34.6, PC2=%23.9, PC3=%17.0, PC4=%13.9, PC5=%7.1, PC6=%3.5

CI/CD veri setinde her bileşen neredeyse eşit varyans açıklamaktadır (~%16.7); bu, PCA'nın boyut indirgeme potansiyelinin sıfır olduğu anlamına gelir. Tüm değişkenler bağımsız ve eşit ağırlıkta bilgi taşımaktadır.

Observability veri setinde ise belirgin bir "dirsek" noktası mevcuttur: ilk 2 bileşen toplam varyansın %58.5'ini, ilk 4 bileşen %89.4'ünü açıklamaktadır. Bu, 5 değişkenin 4 bileşene indirgenebileceğini gösterir. Bu yapı, değişkenler arası korelasyonun (özellikle level_value, has_userId, has_error üçlüsü) PCA tarafından yakalanmasıyla uyumludur.

8.3 PCA 2D Görselleştirme

CI/CD PCA scatter plot'unda severity sınıfları birbirine tamamen karışmış durumdadır; sınıflar arasında görsel

ayrım mümkün değildir. Bu, sayısal özelliklerin hedef değişkeni ayırt etme kapasitesinin düşük olduğunu göstermektedir.

Observability PCA scatter plot'unda ise log_level sınıfları belirgin kümeler oluşturmaktadır; özellikle yüksek seviyeli loglar (CRITICAL, ERROR) düşük seviyeli loglardan (INFO, DEBUG, TRACE) net şekilde ayrılmaktadır. Bu, sınıflandırma modellerinin bu veriden başarılı sonuçlar üretebileceğinin güçlü bir göstergesidir.

---

9. Veri Kalitesi Karşılaştırması

Metrik	CI/CD Pipeline	Software Observability
Eksik Değer	%0.0	language: %88.6, thread: %81.2, service: %37.5, timestamp: %18.8
Tekrarlayan Kayıt	0 (%0.0)	211,377 (%26.42) log, 0 observer
Outlier Durumu	Yok	msg_len: %3.3, level_value: %18.8
Parse Hatası	Yok	0 (başarılı parsing)
Feature Scaling Gerekli mi?	Evet	Evet

Veri kalitesi açısından iki veri seti zıt uçlardadır. CI/CD veri seti "temiz" bir veri setidir: eksik değer, duplikasyon ve outlier yoktur. Bu durum, verinin dikkatli bir şekilde üretildiğini (veya aşırı temizlendiğini) göstermektedir. Observability veri setinde ise gerçek dünya verilerinde sıkça karşılaşılan sorunlar mevcuttur: yüksek oranda eksik değer (bazı sütunlarda %80+), %26 duplikasyon oranı ve outlier'lar. Bu, veri ön işleme aşamasının Observability verisi için çok daha kritik olduğu anlamına gelir.

Her iki veri setinde de feature scaling gereklidir; değişkenler arasındaki ölçek farklılıkları, özellikle mesafe tabanlı algoritmalar (KNN, SVM) ve gradient tabanlı optimizasyon yöntemleri (Neural Networks) için StandardScaler veya MinMaxScaler uygulanmasını zorunlu kılmaktadır.

---

10. Makine Öğrenmesi Uygunluğu Karşılaştırması

Kriter	CI/CD Pipeline	Software Observability
Sınıflandırma Kolaylığı	Düşük (özellikler ayrıştırıcı değil)	Yüksek (güçlü özellik-hedef ilişkisi)
Ön İşleme Karmaşıklığı	Düşük (temiz veri)	Yüksek (eksik veri, duplikasyon, format çeşitliliği)
Boyut İndirgeme Potansiyeli	Yok	Var (6 → 4 bileşen)

Kriter	CI/CD Pipeline	Software Observability
Sınıf Dengesi	Mükemmel	Dengesiz (SMOTE gerekli)
Önerilen Modeller	Ensemble (RF, XGBoost, LightGBM) + feature engineering	NLP tabanlı (TF-IDF + SVM, BERT), Anomaly Detection (Isolation Forest, LSTM)
Feature Engineering İhtiyacı	Yüksek (zaman bazlı türetme)	Orta (metin özellik çıkarımı)

---

11. Sentetik vs. Gerçekçi Veri Tartışması

Analizler ışığında, CI/CD veri setinin sentetik (yapay) bir veri seti olduğuna dair güçlü kanıtlar mevcuttur:

1. **Mükemmel simetrik dağılımlar:** Tüm sayısal değişkenlerin çarpıklık değerleri ≈ 0, basıklık değerleri ≈ -1.2 (uniform dağılım karakteristiği).
2. **Sıfıra yakın korelasyonlar:** Gerçek dünya CI/CD ortamlarında beklenen ilişkiler (build süresi ↔ CPU, memory ↔ deploy süresi) mevcut değil.
3. **Mükemmel sınıf dengesi:** Tüm kategorik değişkenlerde neredeyse eşit dağılım.
4. **Sıfır eksik değer ve outlier:** Gerçek log verilerinde karşılaşılması olası olmayan bir temizlik düzeyi.
5. **PCA'da eşit varyans:** Her bileşenin ~%16.7 varyans açıklaması, bağımsız uniform değişkenlerin tipik davranışıdır.

Observability veri seti ise gerçek dünya verilerine daha yakın karakteristikler sergilemektedir: dengesiz sınıf dağılımı, anlamlı korelasyonlar, yüksek eksik değer oranları ve outlier'lar. Bununla birlikte, bazı alt veri setleri (özellikle Utility Generated) büyük ölçekli sentetik üretim izleri taşımaktadır.

---

12. Özet Karşılaştırma Tablosu

Analiz Boyutu	CI/CD Pipeline	Software Observability	Kazanan
Veri Hacmi	15.33 MB, 45K satır	3.1 GB, 20.8M satır	Observability (büyük veri deneyimi)
Yapısal Basitlik	Tek dosya, tek şema	13 dosya, çoklu format	CI/CD (kolay işlenebilirlik)
Özellik Zenginliği	25 sütun, çeşitli tipler	14+13 sütun, metin ağırlıklı	CI/CD (daha fazla sayısal özellik)
Gerçekçilik	Düşük (sentetik izler güçlü)	Yüksek (doğal dağılımlar)	Observability
Korelasyon Yapısı	Anlamsız (≈ 0)	Anlamlı ve güçlü	Observability
Sınıf Dengesi	Mükemmel	Dengesiz	CI/CD (doğrudan kullanılabilir)

Analiz Boyutu	CI/CD Pipeline	Software Observability	Kazanan
Veri Kalitesi	Kusursuz	Sorunlu (eksik, duplike)	CI/CD (temiz veri)
ML Potansiyeli	Düşük (ayrıştırıcılık zayıf)	Yüksek (güçlü sınıf ayrımı)	Observability
Ön İşleme Zorluğu	Düşük	Yüksek	CI/CD (kolay hazırlık)
Akademik Değer	Orta	Yüksek	Observability

---

13. Sonuç ve Değerlendirme

Bu karşılaştırmalı analiz, iki veri setinin yazılım test optimizasyonu bağlamında farklı güçlü ve zayıf yönlere sahip olduğunu ortaya koymaktadır.

CI/CD Pipeline veri seti, yapısal olarak temiz ve homojen bir veri seti olup, temel veri analizi ve makine öğrenmesi pipeline'ı kurulumu için iyi bir başlangıç noktası oluşturmaktadır. Ancak değişkenler arası ilişkilerin zayıflığı ve sentetik üretim izleri, bu veri seti üzerinde eğitilecek modellerin gerçek dünya performansının sınırlı kalacağına işaret etmektedir. Feature engineering (özellikle zaman bazlı türetme ve kategorik etkileşim özellikleri) bu veri setinin değerini artırabilecek kritik bir adımdır.

Software Observability veri seti, gerçek dünya koşullarını daha iyi yansıtan karmaşık ve zengin bir veri kaynağıdır. Yüksek eksik değer oranları, sınıf dengesizliği ve çoklu format yapısı, veri bilimi sürecinin tüm aşamalarında (veri temizleme, özellik mühendisliği, model seçimi, değerlendirme) derinlemesine çalışma gerektirmektedir. PCA ve korelasyon analizlerinde gözlenen güçlü yapısal ilişkiler, bu veri setinin sınıflandırma ve anomaly detection görevlerinde yüksek performanslı modeller üretme potansiyeli taşıdığını göstermektedir.

Her iki veri seti de yazılım test süreçlerinin yapay zeka ile optimizasyonu açısından tamamlayıcı niteliktedir: CI/CD verisi pipeline düzeyinde hata tahmini için, Observability verisi ise çalışma zamanı anomali tespiti ve log sınıflandırması için değerli kaynaklardır. İdeal bir yazılım test optimizasyonu çözümünde, her iki veri kaynağından elde edilen içgörüler birleştirilmelidir.

Bu rapor, CI/CD Pipeline Hata Logları ve Software Observability veri setlerinin bağımsız analiz raporları temel alınarak hazırlanmıştır.