

XGBoost ile God Class Tahmini - Detayli Analiz Raporu

Veri Seti: Software Quality Attributes Dataset (SQA) **Hedef Degisken:** GodClass (0: Normal Sinif, 1: God Class) **Algoritma:** XGBoost (eXtreme Gradient Boosting) **Tarih:** 2026-03-25

1. Yonetici Ozeti (Executive Summary)

Bu rapor, 10 buyuk olcekli acik kaynak Java projesinden (Spring Framework, Apache Kafka, Selenium vb.) toplanan yazilim kalite metriklerini kullanarak **God Class** anti-pattern'inin otomatik tespiti icin egitilen XGBoost modelinin kapsamli performans analizini sunmaktadir.

Model, **190.707** satirlik orijinal veri setinden **100.000** satirlik rastgele orneklem uzerinde, SMOTE (Synthetic Minority Over-sampling Technique) ile dengelenmis egitim verisi kullanilarak egitilmistir.

Temel Sonuclar

Metrik	Deger	Yorum
Accuracy (Dogruluk)	0.8616 (86.16%)	Genel basari oranı
F1-Score (Macro)	0.6964	Siniflar arasi dengeli F1
F1-Score (Weighted)	0.8438	Agirlikli ortalama F1
ROC-AUC	0.7768	Ayirt edicilik gucu
Average Precision (PR-AUC)	0.5475	Precision-Recall alanı
Matthews Correlation (MCC)	0.4269	Dengeli korelasyon katsayısı
Cohen's Kappa	0.4010	Sansa gore uyum
Brier Score	0.1136	Olasilik kalibrasyon hatasi (dusuk=iyi)
Log Loss	0.3762	Logaritmik kayip

2. Veri On Isleme Ozeti

2.1 Uygulanan Adimlar

1. Hedef Sizintisi (Target Leakage) Onleme:

- mdi_godclass (MDI olasilik skoru) cikarildi - dogrudan hedeften turetilmis bir ozellik.
- QualifiedName, Name, filename gibi ID sutunlari cikarildi.

2. Multicollinearity Cozumu:

- WMC.1 ve LOC.1 (tam kopya ozellikler, r=1.0) cikarildi.
- VIF > 10 olan ciddi multicollinearity bulunmamasina ragmen, kopya sutunlar elimine edildi.

3. Eksik Veri Isleme:

- Paket ve metot düzeyindeki tamamen boş (%100 NaN) 14 sütun çıkarıldı.
- Kalan %0.03 oranındaki eksik değerler medyan ile dolduruldu.


4. **Ölçeklendirme:** **RobustScaler** kullanıldı (aşırı uç değerlere karşı dayanıklı).

5. **Kategorik Encoding:** **Complexity, Coupling, Size, Lack of Cohesion** kategorik değişkenleri One-Hot Encoding ile dönüştürüldü.

6. **SMOTE (Sınıf Dengeleme):**

- Orijinal dağılım: GodClass=%17.11, Non-GodClass=%82.89
- SMOTE sonrası eğitim seti: %50-%50 dengeli hale getirildi
- Test setine SMOTE uygulanmadı (gerçekçi değerlendirme için)

2.2 Sınıf Dağılımı



3. Sınıflandırma Performansı


3.1 Sınıf Bazlı Metrikler

Sınıf	Precision	Recall	F1-Score	Support
Non-GodClass (0)	0.8802	0.9643	0.9203	16583
GodClass (1)	0.6769	0.3629	0.4725	3417

Kritik Gözlem: Non-GodClass sınıfı için recall %96.4 gibi çok yüksek bir değerken, GodClass sınıfı için recall %36.3 seviyesindedir. Bu, modelin GodClass örneklerinin önemli bir kısmını kaçırdığını göstermektedir. Ancak GodClass için precision %67.7 olup, model "bu bir GodClass" dediğinde çoğunlukla doğrudur.

3.2 Confusion Matrix


XGBoost - Confusion Matrix Analizi

**Confusion Matrix Yorumu:**

- **True Negative (TN):** 15,991 sınıf dogru sekilde "Normal" olarak siniflandirildi.
- **False Positive (FP):** 592 normal sınıf yanlis olarak "GodClass" etiketlendi.
- **False Negative (FN):** 2,177 GodClass yanlis olarak "Normal" etiketlendi.
- **True Positive (TP):** 1,240 GodClass dogru sekilde tespit edildi.

4. Ayirt Edicilik Analizi


4.1 ROC Egrisi



ROC-AUC degeri **0.7768** olup, modelin siniflar arasinda guclu bir ayrim yapabildigini gostermektedir. Bu deger:


- 0.90-1.00: Mukemmel
- **0.80-0.90: Çok iyi** <-- Modelimiz bu kategoride
- 0.70-0.80: Iyi
- 0.60-0.70: Zayif
- 0.50-0.60: Basarisiz

4.2 Precision-Recall Egrisi



Average Precision (AP) degeri **0.5475** olup, dengesiz veri setlerinde daha gercekci bir performans gostergesidir. Bazal prevalans oraninin (GodClass orani test setinde 0.171) uzerinde anlamlı bir iyilestirme saglanmistir.


4.3 Kumulatif Kazanc Egrisi



Bu grafik, modelin en yuksek GodClass olasiligiyla siralanan orneklerin ne kadarini dogru yakalayabildigini gostermektedir. Ornegin, tum orneklerin sadece **%20'sini** inceleyerek GodClass siniflarin buyuk bir kismini tespit etmek mumkundur. Bu, test sureci onceliklendirmesinde buyuk zaman tasarrufu saglar.

5. Ozellik Onem Analizi (Feature Importance)

5.1 En Onemli 20 Ozellik



5.2 En Onemli 15 Ozellik Tablosu


Sira	Ozellik	Onem Degeri
1	Lack of Cohesion_low	0.103551
2	ps_NOM	0.068570
3	ps_ATFD	0.066508
4	LOC	0.053395
5	Size_low	0.053114
6	ps_LOC	0.050777
7	ps_WMC	0.048751
8	NOM	0.033642
9	Lack of Cohesion_medium-high	0.031554
10	WMC	0.030418
11	SRFC	0.030018
12	ps_LTCC	0.029620
13	Lack of Cohesion_low-medium	0.028862
14	Coupling_low	0.026296

Sıra	Ozellik	Onem Degeri
15	Unnamed: 0	0.026231

Akademik Yorum:

- Sınıf karmaşıklığı metrikleri (**WMC, LOC, CMLOC**) en belirleyici özelliklerdir; bu, God Class'ların temel özelliği olan "aşırı sorumluluğun" doğrudan sınıf boyutuyla ilişkili olduğunu doğrulamaktadır.
- Bağımlılık metrikleri (**CBO, RFC, SRFC**) de yüksek önem taşımaktadır; bu, God Class'ların diğer sınıflarla aşırı etkileşimde bulunduğunu göstermektedir.
- Uyum metrikleri (**LCOM, LCAM, LTCC**) düşük sıralarda yer almaktadır; bu, God Class tespitinde uyum eksikliğinden çok boyut ve karmaşıklığın belirleyici olduğunu göstermektedir.

6. Karar Esigi (Threshold) Analizi




Varsayılan karar esigi 0.5'tir. Ancak farklı esik değerleri farklı kullanım senaryoları için optimize edilebilir:

Senaryo	Onerilen Esik	Aciklama
Yuksek Precision	0.70-0.80	"GodClass" dediginde cok emin olmak istiyorsanız
Dengeli	0.40-0.50	F1-Score'u maksimize eder
Yuksek Recall	0.20-0.30	Hicbir GodClass'i kacirmamak istiyorsanız


7. Olasilik Kalibrasyon Analizi

7.1 Olasilik Dagilimi



Yorum: Non-GodClass orneklerinin buyuk cogunlugu 0'a yakin olasilik alirken, GodClass orneklerinin olasiliklari daha genis bir araliga dagilmistir. Bu durum, bazi GodClass orneklerinin "sinirdaki" (borderline) vakalar oldugunu ve modelin bunlari ayirt etmekte zorlandigini gostermektedir.


7.2 Kalibrasyon Egrisi



Brier Score: 0.1136 (0'a yakın = iyi kalibrasyon)

Kalibrasyon egrisi, modelin tahmini olasiliklerinin gercek olasiliklerle ne kadar uyumlu oldugunu gostermektedir.

8. Hata Analizi



Bu grafik, her Confusion Matrix kategorisindeki (TN, FP, FN, TP) orneklerin model tarafından atanan olasilik dagilimini gostermektedir:

- **FN (False Negative):** Kacirilan GodClass'lar genellikle dusuk olasilik almistir, yani bunlar "hafif" God Class ozellikleri gosteren sinirdaki vakalerdir.
- **FP (False Positive):** Yanlis alarm verilen normal siniflar genellikle yuksek karmasikliga sahip ancak asil GodClass olmayan siniflardir.

9. Projelerde Kullanım Senaryolari

9.1 CI/CD Pipeline Entegrasyonu (Otomatik Kod Kalitesi Kontrolu)

Akim:

```
Git Push -> CI/CD Pipeline -> Kod Metrikleri Cikarimi (CK Tool) ->
XGBoost Modeli ile Tahmin -> God Class Uyarisi/Engelleme
```

Uygulama: Jenkins, GitHub Actions veya GitLab CI pipeline'ına eklenen bir adım olarak, her commit'te degistirilen sinifların CK metrikleri cikarılır ve model üzerinden gecirilerek otomatik God Class uyarisi verilir. Threshold degeri ekibin hassasiyet tercihine gore ayarlanabilir.

9.2 IDE Eklentisi (Real-Time Kod Kokusu Tespiti)

Uygulama: IntelliJ IDEA veya Eclipse eklentisi olarak gelistirilerek, gelistirici kodu yazarken arka planda surekli metrikleri hesaplayip, GodClass olma olasiligi yuksek siniflar icin anlik uyarilar verir.

Avantaj: Sorun buyumeden, kod yazim asamasinda tespit edilir.

9.3 Teknik Borc Yonetim Sistemi

Uygulama: Buyuk projelerde tum siniflarin periyodik olarak (ornegin haftalik) taranmasi ve GodClass risk skorlarinin bir dashboard uzerinde gosterilmesi. Proje yoneticileri en yuksek riskli siniflari refactoring backlog'una ekleyebilir.

9.4 Egitim ve Mentoring Araci

Uygulama: Junior geliřtiricilerin yazdigi kodlar uzerinde model calistirilarak, hangi tasarim kararlarinin God Class'a yol actigini somut olarak gosterir.

10. Akademik Bildiri ve Yayin Onerileri

10.1 Bildiri Konusu Onerileri

1. "XGBoost ile Yazilim Kod Kokularinin Otomatik Tespiti: God Class Uzerine Bir Uygulama"

- *Hedef Konferans:* UBMK (Uluslararası Bilgisayar Bilimleri ve Muhendisligi Konferansi), ASYU (Akıllı Sistemlerde Yenilikler ve Uygulamaları)
- *Icerik:* Bu calismadaki tum pipeline, veri on isleme, SMOTE uygulaması ve model karsilastirma sonuclari

2. "Dengesiz Veri Setlerinde SMOTE ve Agac Tabanlı Ensemble Yontemlerinin Yazilim Kalite Tahminine Etkisi"

- *Hedef Dergi:* Journal of Software: Evolution and Process, Empirical Software Engineering
- *Icerik:* SMOTE uygulanmadan onceki ve sonraki model performans farklarinin istatistiksel olarak karsilastirilmesi

3. "Acik Kaynak Java Projelerinde God Class Anti-Pattern'inin Makine Ogrenmesi ile Tahmin Edilmesi"

- *Hedef Konferans:* IEEE/ACM International Conference on Mining Software Repositories (MSR)
- *Icerik:* 10 farkli projede cross-project validation ile modelin genellenebilirliğinin test edilmesi

10.2 Bildiri Yapisi Onerisi

1. Giriş (Introduction)
 - Yazilim kod kokulari ve God Class problemi
 - Motivasyon ve Arařtırma sorulari
2. Ilgili Calismalari (Related Work)
 - Geleneksel God Class tespit yontemleri (esik degeri tabanlı)
 - Makine ogrenmesi tabanlı yaklaşımlar
3. Yontem (Methodology)
 - Veri seti aciklamasi (10 proje, 190K+ sinif)
 - Veri on isleme pipeline'i

- SMOTE uygulaması ve gerekcelendirmesi
 - XGBoost hiperparametre seçimi
4. Deneysel Sonuclar (Experimental Results)
 - Model performans karsilastirmasi (XGBoost vs RF vs LR vs KNN vs LGBM)
 - ROC-AUC, PR-AUC, MCC analizi
 - Feature importance ve yorumlanabilirlik
 - Cross-project validation sonuclari
 5. Tartisma ve Tehditler (Discussion & Threats to Validity)
 - Internal threats: SMOTE bias, esik degeri secimi
 - External threats: Farkli dillerdeki projelerde genellenebilirlik
 6. Sonuc ve Gelecek Calismalari (Conclusion)

10.3 Arastirma Sorulari (Research Questions)

- **RQ1:** XGBoost modeli, God Class anti-pattern'ini ne olcude basariyla tahmin edebilmektedir?
- **RQ2:** SMOTE ile sinif dengelemenin model performansina etkisi nedir?
- **RQ3:** Hangi yazilim metrikleri God Class tespitiinde en belirleyici ozelliklerdir?
- **RQ4:** Model, farkli projeler arasinda genellenebilir mi (cross-project validation)?

11. Model Sinirlamalari ve Gelecek Calismalari

11.1 Bilinen Sinirlamalar

1. **Dil Sinirlamasi:** Model yalnızca Java projeleri üzerinde eğitilmiştir. Python, C# gibi dillerde farklı metrikler ve eşik değerleri gerekebilir.
2. **GodClass Recall Sorunu:** %36.3'lük recall, gerçek God Class'ların yaklaşık 2/3'unun kaçırıldığı anlamına gelmektedir.
3. **Statik Analiz Siniri:** Model sadece statik kod metriklerini kullanmaktadır; runtime davranışı, değişim geçmişi (change history) ve geliştirici niyeti gibi dinamik bilgileri işlemez.
4. **SMOTE Artifakti:** Sentetik azınlık örnekleri, gerçek veri dağılımını tam olarak yansıtmayabilir.

11.2 Gelecek Calisma Onerileri

1. **Threshold Optimizasyonu:** F1-Score'u maksimize eden optimal eşik değerinin belirlenmesi (şu an 0.5 varsayılan değer kullanılmaktadır).
2. **Hiperparametre Tuning:** GridSearchCV veya Optuna ile XGBoost hiperparametrelerinin (max_depth, learning_rate, n_estimators, scale_pos_weight) optimize edilmesi.
3. **Cross-Project Validation:** Modelin bir projede eğitilip başka bir projede test edilerek genellenebilirliğinin değerlendirilmesi.
4. **SHAP Analizi:** Her bir tahmin için bireysel özellik katkısının açıklanması (Explainable AI).
5. **Ensemble Yaklaşımı:** XGBoost, LightGBM ve Random Forest'in soft-voting ile birleştirilmesi.
6. **Deep Learning:** LSTM veya Transformer tabanlı modellerin kod token dizileri üzerinde denenmesi.

12. Teknik Appendiks

12.1 Model Hiperparametreleri

XGBoost modeli varsayılan parametrelerle eğitilmiştir:

- `eval_metric`: logloss
- `random_state`: 42
- `n_jobs`: -1 (tüm CPU çekirdeklerini kullan)
- `use_label_encoder`: False

12.2 Dosya Yapısı

```
sqa/xgboost/
|-- xgboost_model.joblib          # Kaydedilmiş model (~350 KB)
|-- metrics.json                 # Temel metrikler
|-- confusion_matrix.png         # Basit CM grafiği
|-- feature_importance.png       # Basit FI grafiği
|-- analysis/
|   |-- xgboost_detailed_report.md # Bu rapor
|   |-- images/
|       |-- confusion_matrix_detailed.png
|       |-- roc_curve.png
|       |-- precision_recall_curve.png
|       |-- feature_importance_top20.png
|       |-- threshold_analysis.png
|       |-- probability_distribution.png
|       |-- calibration_curve.png
|       |-- class_distribution.png
|       |-- error_analysis_boxplot.png
|       |-- cumulative_gains.png
```

12.3 Kullanılan Kutuphaneler

Kutuphane	Surum	Amac
xgboost	>=1.7	Gradient Boosting modeli
scikit-learn	>=1.2	Metrikler, preprocessing
imbalanced-learn	>=0.10	SMOTE
matplotlib	>=3.7	Gorsellestirme
seaborn	>=0.12	Istatistiksel gorsellestirme
pandas	>=1.5	Veri manipülasyonu
joblib	>=1.2	Model serializasyonu

Bu rapor, otomatik analiz skripti tarafından oluşturulmuştur. Tarih: 2026-03-25